## IML\_project

## Heikki Nenonen

## 2022-11-22

## Todo

- · dummy classifier
- class4 -> event/nonevent, week1 exe?
- varianssit mukana/ei mukana? ei one hot -> yksinkertaistaa liikaa ja tarkoitettu kategoriseen dataan
- date? paljon informaatiota, mutta halutaanko muuttujaksi <- opeta 2000-2008, testaa 2009-2011 / kysy slack test\_hidden ei - - date, jätetäänkö pois?
- train, test, cv-10?
- itse logisticregression, week2 exe1 <- lasso/ridge
- accuracy, perplexity, week2 exe1
- accuracy of our accuracy? <- malli train+test, vähän parempi kuin pelkkä train?
- class4 -> nonevent/1a/1b/II/
- googlaa mahdollisia malleja

```
# Python with sklearn
import pandas as pd
from sklearn import linear_model

#npf_test = pd.read_csv("initial_data/npf_test_hidden.csv")

npf_train = pd.read_csv("initial_data/npf_train.csv")

npf_train
```

```
##
         id
                    date
                             class4
                                           UV_B.std
                                                       CS.mean
                                                                   CS.std
## 0
             2000-01-17
                                           0.018122
                                                     0.000243
                                                                0.000035
          1
                                 Ιb
## 1
          2
             2000-02-28
                          nonevent
                                          0.003552
                                                     0.003658
                                                                0.000940
                                          0.272472
## 2
          3
             2000-03-24
                                                     0.000591
                                                                0.000191
                                 Ib
## 3
          4
             2000-03-30
                                           0.451830
                                                     0.002493
                                                                0.000466
                                 ΙI
## 4
          5
             2000-04-04
                                           0.291457
                                                     0.004715
                                                                0.000679
                         nonevent
##
                                . . .
                                                . . .
                                                           . . .
        . . .
                     . . .
## 459
        460
             2011-08-16
                                          0.496816
                                                     0.002423
                                                                0.000425
                          nonevent
## 460
        461
             2011-08-19
                                          0.726461
                                                     0.002476
                                                                0.000902
                          nonevent
             2011-08-21 nonevent
                                          0.363890
                                                     0.003484
## 461
        462
                                                                0.000457
```

```
## 462 463 2011-08-22 nonevent ... 0.595032 0.004782 0.001082
## 463 464 2011-08-27 nonevent ... 0.722553 0.006956 0.000605
## ## [464 rows x 104 columns]
```